

Metody Monte Carlo

Raport 5

Autor: Imię i nazwisko

Dzisiejsza data


Spis treści

- 1 Problem 1 – Zbieżność łańcuchów Markowa 2
- 2 Problem 2 – Metoda Metropolis-Hastingsa i próbnik Gibbsa 3
- 3 Problem 3 – Wartości krytyczne i moce testu 4

1

1 Problem 1 – Zbieżność łańcuchów Markowa

Szczur chodzi losowo po pokojach. (a) Znajdź numerycznie asymptotyczną częstość przebywania w pokoju 7. Zilustruj ten wynik: potwierdź (b) słabe twierdzenie ergodyczne oraz (c) mocne prawo wielkich liczb przy pomocy symulacji.



Rozwiązanie:

```
set.seed(131311)
```

```
tab <- vector("list", 7)
tab[[1]] <- c(0, 1/2, 1/2, 0, 0, 0, 0)
tab[[2]] <- c(1/2, 0, 0, 1/2, 0, 0, 0)
tab[[3]] <- c(1/2, 0, 0, 1/2, 0, 0, 0)
tab[[4]] <- c(0, 1/3, 1/3, 0, 0, 0, 1/3)
tab[[5]] <- c(0, 0, 0, 0, 0, 1, 0)
tab[[6]] <- c(0, 0, 0, 0, 1/2, 0, 1/2)
tab[[7]] <- c(0, 0, 0, 1 / 2, 0, 1 / 2, 0)
```

```
zad1 <- function(n) {
  rat <- 1
  pi <- c(0, 0, 0, 0, 0, 0, 0)
  for (i in 1:n) {
    u <- runif(1)
    for (j in 1:7) {
      u <- u - tab[[rat]][j]
      if (u < 0) {
        rat <- j
        pi[j] <- pi[j] + 1
        break
      }
    }
  }
  return(pi/n)
}
```


```
room <- function(n) {
  rat <- 1
  pi <- c(0, 0, 0, 0, 0, 0, 0)
  for (i in 1:n) {
    u <- runif(1)
    for (j in 1:7) {
      u <- u - tab[[rat]][j]
      if (u < 0) {
        rat <- j
        break
      }
    }
  }
  return(rat)
}
c <- c(0, 0, 0, 0, 0, 0, 0)
M = 10000
for (i in 1:M) {
  temp <- room(100 + floor(rnorm(1)))
  c[temp] <- c[temp] + 1
}
c <- c / M
print(c)
```

```
## [1] 0.1382 0.1425 0.1379 0.2187 0.0763 0.1429 0.1435
```

```

values <- zad1(10000)
plot(c(1, 2, 3, 4, 5, 6, 7), values)
lines(zad1(10000), type="p", col = "red")
lines(c, col = "blue") (podpunkt B)

```



```

PWL <- c(0, 0, 0, 0, 0, 0, 0)
for (i in 1:M) {
  temp <- room(100 + floor(rnorm(1)))
  PWL[temp] <- PWL[temp] + 1
}
for (i in 1:7) {
  PWL[i] <- PWL[i] * i
}
PWL <- sum(PWL)/M
print(PWL)

## [1] 3.905

x <- 0
for (i in 1:7) {
  x <- c[i]*i + x
}
print(x)

## [1] 3.9551

```

Problem 2 – Metoda Metropolis-Hastingsa i próbnik Gibbsa

(a) (Podstawy MH)

- Sprawdź, że jeżeli $q(x,y)$ jest macierzą przejścia w jednym kroku, a $f(x)$ jest rozkładem, oraz spełniony jest warunek równowagi $f(x)q(x,y) = f(y)q(y,x)$, to f jest rozkładem stacjonarnym.
- Niech f będzie rozkładem, $q(x,y)$ prawdopodobieństwem przejścia a

$$\alpha(x, y) = \min \left(1, \frac{f(y)q(y, x)}{f(x)q(x, y)} \right)$$

tz. prawdopodobieństwem akceptacji. Niech $q^{\sim}(x,y) = \alpha(x,y)q(x,y) + (1-\alpha(x,y))\delta_x(y)$. Sprawdź, że f jest rozkładem stacjonarnym dla $q^{\sim}$.

(b) (Zastosowanie MH do MCMC) Chcemy aproksymować całkę $\int_0^{\infty} \frac{x \log x}{1+x} e^{-\sqrt{x}-x} dx$.

- Sprawdź, że $q(x,y) = yx^{-2}e^{-y/x}$ definiuje prawdopodobieństwo przejścia.
- Zaimplementuj MH dla otrzymania łańcucha Markowa o rozkładzie stacjonarnym $c \frac{x |\log x|}{1+x} e^{-\sqrt{x}-x} dx$ i aproksymacji powyższej całki. (c) (Niezależne propozycje w MH)
- Niech $q(x,y) = q(y)$, $f \geq 0$. Losujemy kandydata y , którego akceptujemy z prawdopodobieństwem 1 jeżeli $f(x)q(y) = 0$, a w pozostałych przypadkach z prawdopodobieństwem $\alpha(x, y) = \min \left(1, \frac{f(y)q(x)}{f(x)q(y)} \right)$. Jaki jest rozkład stacjonarny?
- Użyj MH do przybliżonego generowania z rozkładu $c(\cos x + x)^{-3}$ na $(0, \infty)$, gdy $q(y) = c'(1 + y)^{-3}$ na $(0, \infty)$.

(d) (Próbnik Gibbsa)

- Użyj PG do generowania rozkładu $N \left(0, \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix} \right)$, tj. symuluj $X_1|X_2 = x_2 \sim N(\rho x_2, 1 - \rho^2)$, $X_2|X_1 = x_1 \sim N(\rho x_1, 1 - \rho^2)$ itd.
- Zbadaj czas burn-in.
- Zilustruj rozkład docelowy i zbadaj kowariancję współrzędnych.

Rozwiązanie:

```
rho <- 0.5


cond <- function(x, y, rho) {
  dnorm(x, rho * y, sqrt(1 - rho ^ 2))
}
```

```
x0 <- c(3, 1)

n <- 600
x <- matrix(NA, nrow = n, ncol = 2)
x[1,] <- x0
for (i in 2:n) {
  x[i, 1] <- rnorm(1, rho * x[i - 1, 2], sqrt(1 - rho ^ 2))
  x[i, 2] <- rnorm(1, rho * x[i, 1], sqrt(1 - rho ^ 2))
}

burn.in <- 300
y <- head(x, burn.in)
x <- x[(burn.in + 1):n,]


par(mfrow = c(1, 2))
plot(x[, 1], x[, 2])
abline(h = 0, v = 0, lty = 2)
```



```
cov(x)


##           [,1]      [,2]
## [1,] 1.0048970 0.5284927
## [2,] 0.5284927 1.0086549
```

```
plot(x[, 1], type = "p", xlab = "Iteracja", ylab = "X1")
```



Jest to wykres próbek 300-600 i jak widać rozrzut jest w miarę losowy

```
plot(y[, 1], type = "p", xlab = "Iteracja", ylab = "Y1")
```



Tutaj Mamy próbki od 0 – 300 I widać że pierwsze 200 zachowuje się nie jak rozkład normalny

Problem 3 – Wartości krytyczne i moce testu

- (a) Podaj statystkę testu Kołmogorowa-Smirnowa dla jednostajności na $(0,1)$.
- (b) Znajdź empirycznie wartości krytyczne dla poziomu istotności 0,05 i rozmiaru próby $n = 50, 100, 200$.
- (c) Znajdź empirycznie moce testu KS dla wybranych rozkładów beta.

Rozwiązanie:

```
n <- 100
sample <- runif(n)

result <- ks.test(sample, "punif")
print(result$statistic)

##          D
## 0.08853892

B

alpha <- 0.05
val <- c(50, 100, 200)
num <- 10000

sim <- function(n, alpha, num) {
  kss <- num

  for (i in 1:num) {
    sample <- runif(n)
    kss[i] <- ks.test(sample, "punif")$statistic
  }

  crit <- quantile(kss, 1 - alpha)
  return(crit)
}

critical <- sapply(val, sim, alpha, num)

critical

##          95%          95%          95%
## 0.18769260 0.13322644 0.09551962

C
```



```
alpha <- 0.05
n <- 100
num <- 10000
beta <- list(c(1, 1), c(15, 5), c(5, 15), c(1, 15))

ks <- function(n, alpha, num, shape1, shape2) {
  reject <- 0

  for (i in 1:num) {
    sample <- rbeta(n, shape1, shape2)
    kss <- ks.test(sample, "pbeta", shape1, shape2)$statistic

    crit <- 1.36 / sqrt(n)

    if (kss > crit) {
      reject <- reject + 1
    }
  }

  power <- reject / num
  return(power)
}

powers <- sapply(beta, function(params) {
  ks(n, alpha, num, params[1], params[2])
})
powers
## [1] 0.0457 0.0449 0.0489 0.0442
```